中山大学计算机院本科生实验报告

（2024 学年春季学期）

课程名称：并行程序设计　　批改人：

实验	Lab0-环境设置与串行矩阵乘法	专业（方向）	计算机科学与技术
学号	21307174	姓名	刘俊杰
Email	liujj255@mail2.sysu.edu.cn	完成日期	2024/3/25

1. 实验目的

本实验的主要目的是通过实现串行矩阵乘法，并对比不同版本的实现在性能上的差异，分析不同因素对最终性能的影响。具体来说，实验将探讨以下几个方面：

实现多个版本的串行矩阵乘法，包括 Python、C/C++等不同语言的实现，以及针对 C/C++代码的优化方式，如调整循环顺序、编译优化、循环展开等。

通过对比不同版本的运行时间，分析各种实现方式的性能差异，探讨不同因素对性能的影响。

计算相对加速比、绝对加速比、浮点性能（GFLOPS）以及峰值性能百分比等指标，评估各种实现方式的效果。

2. 实验过程和核心代码

2.1 Python 版本实现

```python
# 执行矩阵乘法
def matrix_multiplication(A, B):
    m = len(A)
    n = len(A[0])
    k = len(B[0])
    C = [[0] * k for _ in range(m)]
    for i in range(m):
        for j in range(k):
            for l in range(n):
                C[i][j] += A[i][l] * B[l][j]
    return C
```

(这里初步的三重循环设计的原因在 2.2 中提及)

2.2 C/C++版本实现

```cpp
// 执行矩阵乘法
void matrixMultiplication(double** A, double** B, double** C, int m, int n, int k) {
    for (int i = 0; i < m; ++i) {
        for (int j = 0; j < k; ++j) {
            for (int l = 0; l < n; ++l) {
                C[i][j] += A[i][l] * B[l][j];
            }
        }
    }
}
```

为了比较方便后续的循环调整，这里**在矩阵乘法进行前先将矩阵 C 赋值为 0 矩阵**。

其次可以先通过**局部性**，确定三重循环的最外层循环为:

`for(int i = 0; i< m; ++i)`

因为将这一层循环放在最外层能够保证矩阵 C 和矩阵 A 不会出现频繁的未命中而导致的延时，否则会出现多次类似取 C[i]到取 C[i+1]而导致的 c[i+1]元素的未命中。

为了与后续比较这里先确定 `m -> k -> n` 的三重循环顺序:

2.3 调整循环顺序

相较于上一步优化 m -> k -> n 的循环顺序，这里调整循环顺序为 m -> n -> k。

因为将 n 放在第二重循环能相较于上一步更大的利用矩阵 B 的局部性。

```
// 执行矩阵乘法(调整循环优化)
void matrixMultiplication(double** A, double** B, double** C, int m, int n, int k) {
    for (int i = 0; i < m; ++i) {
        for (int l = 0; l < n; ++l) {
            for (int j = 0; j < k; ++j) {
                C[i][j] += A[i][l] * B[l][j];
            }
        }
    }
}
```

2.4 编译优化

编译命令:

-O1:

-O1 是一种基本的优化级别，它启用了一些简单的优化，例如删除未使用的变量、内联简单函数、去除无效的代码、简化表达式等。这些优化不会增加代码的大小，但可以提高代码的执行效率。

-O2:

-O2 是一个中等优化级别，它在 -O1 的基础上增加了更多的优化手段，例如更进一步的代码内联、函数调用优化、循环展开、消除冗余计算、基于数据流的优化等。这些优化可以显著提高程序的执行速度，但可能会增加编译时间和生成的代码大小。

-O3:

-O3 是最高级别的优化选项，它在 -O2 的基础上进行了更加激进的优化，例如更大规模的循环展开、更多的向量化操作、更深入的函数内联、更多的优化阶段等。这些优化可能会导致编译时间的显著增加，以及生成的代码大小的增加，但通常能够带来最大的性能提升。

2.5 循环展开

循环展开，英文中称 Loop unwinding 或 loop unrolling，是一种牺牲程序的尺寸来加快程序的执行速度的优化方法。可以由程序员完成，也可由编译器自动优化完成。循环展开最常用来降低循环开销，为具有多个功能单元的处理器提供指令级并行。也有利于指令流水线的调度。

循环展开对程序性能有着很重要的影响，**可以减少分支预测错误次数，增加取消数据相关**进一步利用并行执行提高速度的机会。

这里利用循环展开进行优化(要注意越界问题)

```
// 执行矩阵乘法(调整循环优化 + 循环展开)
void matrixMultiplication(double** A, double** B, double** C ,int m, int n, int k) {
    for (int i = 0; i < m; ++i) {
        for (int l = 0; l < n; ++l) {
            for (int j = 0; j < k; j+=4) { // 循环展开，每次处理4个元素
                C[i][j] += A[i][l] * B[l][j];
                if (j + 1 < k)  // 检查是否越界
                    C[i][j+1] += A[i][l] * B[l][j+1];
                if (j + 2 < k)
                    C[i][j+2] += A[i][l] * B[l][j+2];
                if (j + 3 < k)
                    C[i][j+3] += A[i][l] * B[l][j+3];
            }
        }
    }
}
```

2.6 Intel MKL

Intel Math Kernel Library（MKL）是英特尔提供的数学核心库，旨在提高在英特尔处理器上执行数学和科学计算的性能。MKL 提供了一系列高度优化的数学函数和算法，包括线性代数、傅立叶变换、随机数生成等，可以显著加速科学计算、工程计算和数据分析等应用程序。

```
clock_t start = clock();
cblas_dgemm(CblasRowMajor, CblasNoTrans, CblasNoTrans, m, k, n, 1.0, A, n, B, k, 0.0, C, k);
clock_t end = clock();
double time_spent = ((double)(end - start)) / CLOCKS_PER_SEC * 1000;
```

3. 实验结果

3.1 Python 版本

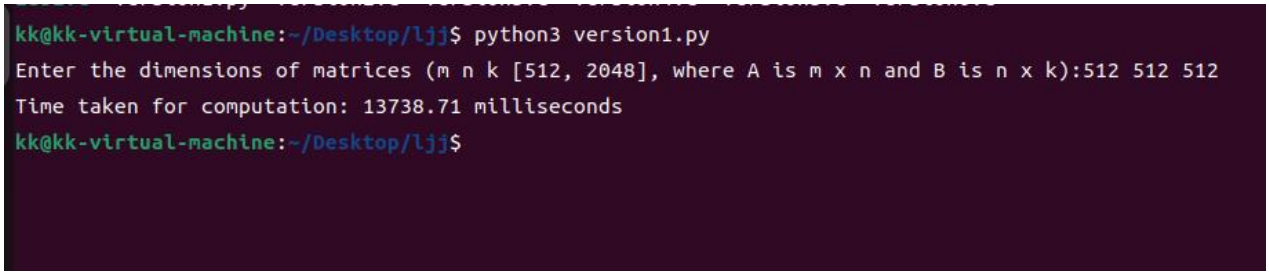

3.2 C/C++版本

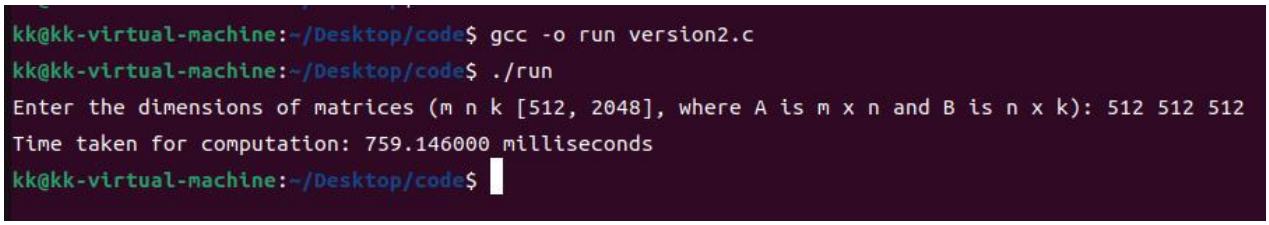

Python 执行比 C/C++慢的原因:

1. 动态类型和解释执行： Python 是一种动态类型语言，而 C 是一种静态类型语言。Python 在运行时需要进行类型检查和解释执行，这会导致额外的性能开销。相比之下，C 是一种静态类型语言，在编译时进行类型检查并生成机器码，因此执行速度更快。

2. 解释器和虚拟机开销：*Python 是一种解释执行的语言，它的代码由解释器逐行解释并执行。另外，Python 代码通常在虚拟机中运行，这也会增加一些额外的开销。相比之下，C 代码是直接编译成机器码执行的，没有解释器和虚拟机的开销。

3. 优化和编译器技术： C 是一种编译型语言，它的代码在编译时会经过优化和静态分析，生成高效的机器码。与此相比，Python 的代码是在运行时动态解释执行的，编译器无法进行静态优化。

3.3 调整循环顺序

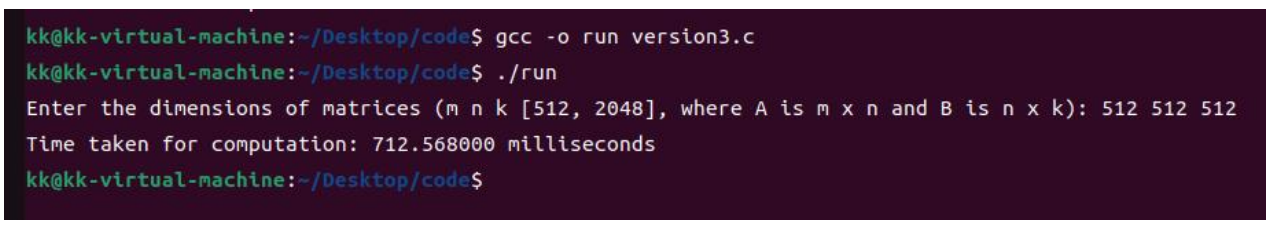

3.4 编译优化

```
kk@kk-virtual-machine:~/Desktop/code$ gcc -o run version4.c
kk@kk-virtual-machine:~/Desktop/code$ ./run
Enter the dimensions of matrices (m n k [512, 2048], where A is m x n and B is n x k): 512 512 512
Time taken for computation: 616.350000 milliseconds
kk@kk-virtual-machine:~/Desktop/code$
```

3.5 循环展开

```
kk@kk-virtual-machine:~/Desktop/code$ gcc -o run version5.c
kk@kk-virtual-machine:~/Desktop/code$ ./run
Enter the dimensions of matrices (m n k [512, 2048], where A is m x n and B is n x k): 512 512 512
Time taken for computation: 638.656000 milliseconds
kk@kk-virtual-machine:~/Desktop/code$
```

3.6 Intel MKL

```
kk@kk-virtual-machine:~$ cd Desktop/code
kk@kk-virtual-machine:~/Desktop/code$ gcc -o runmkl version6.c -I/opt/intel/oneapi/mkl/2024.0/include -L/opt/intel/oneapi/mkl/2024.0/lib/intel64 -lmkl_intel_lp64 -lmkl_sequential -lmkl_core -lpthread -lm -ldl
kk@kk-virtual-machine:~/Desktop/code$ ./runmkl
Enter the dimensions of matrices (m n k [512, 2048], where A is m x n and B is n x k): 512 512 512
Time taken for computation: 21.782000 milliseconds
kk@kk-virtual-machine:~/Desktop/code$
```

3.7 综合对比

矩阵规模:

A: 512 X 512
B: 512 X 512
C: 512 X 512

虚拟机配置:
1 个处理器，共 2 个核
浮点计算单元为 8
时钟频率为 2495.311 MHZ
峰值性能估计为 39.925 GFLOPS

版本	实现描述	运行时间 (sec.)	相对 加速比	绝对 加速比	浮点性能 (GFLOPS)	峰值性能 百分比
1	Python	13.73871	1	1	0.019	0.048%
2	C/C++	0.759146	18.097586	18.097586	0.353	0.885%
3	调整循环顺序	0.712568	1.065366	19.280560	0.376	0.943%
4	编译优化	0.616350	1.156109	22.290436	0.435	1.090%
5	循环展开	0.638656	0.965074	21.511909	0.420	1.052%
6	Intel MKL	0.021782	29.320356	630.736847	12.323	30.867%

4. 实验感想

在本次实验中，我对串行矩阵乘法的实现和优化进行了深入探索，在实验中收获了一些感想：

在本次实验中，我掌握了串行矩阵乘法的实现和优化技巧，也提升了自己在编程和性能优化方面的能力。通过本次实验，对比了多种串行矩阵乘法的优化方法，包括循环调整、编译优化、循环展开以及使用 Intel MKL 库等，我了解了这些优化方法是如何优化矩阵乘法的。并且通过对实验结果的比较，我加深了算法优化对性能提升的重要性的认识。